



Universidade Federal de Santa Catarina – UFSC
Centro Tecnológico – CTC
Departamento de Informática e Estatística – INE

INE410159 – Visão Computacional

**DETECÇÃO DE ANOMALIAS EM PAINÉIS SOLARES
UTILIZANDO TÉCNICAS DE VISÃO COMPUTACIONAL**

Autores:

Gabriel Vinicius Crippa - 20206969

Gustavo Portela Alves - 21100467

Júlia Sebold May - 21101148

Yuri Melo Nunes - 20104163

Florianópolis, 27 de junho de 2026.

Sumário

1	Introdução	3
2	Dataset	4
3	Solução com visão clássica	5
3.1	Preparação do ambiente e análise exploratória dos dados	5
3.2	<i>Pipeline</i> de análise inicial	5
3.3	Extração de características e comparação de classificadores	6
4	Solução com <i>deep learning</i>	8
5	Conclusão	11

1 Introdução

A transição energética tem impulsionado a adoção de fontes de energia limpa e renovável. Os sistemas fotovoltaicos se destacam como uma das principais alternativas dentro da expansão das fontes renováveis, sendo amplamente empregados em instalações residenciais e comerciais. Esses sistemas utilizam módulos solares para converter diretamente a radiação solar em energia elétrica, permitindo a geração distribuída e reduzindo a dependência de fontes convencionais de energia.

Durante sua vida útil, os módulos fotovoltaicos estão sujeitos a intempéries e desgastes operacionais que podem gerar anomalias, comprometendo o potencial de geração de energia. Atualmente, a identificação e a correção dessas falhas dependem de inspeções termográficas periódicas. A abordagem convencional envolve a medição manual em campo utilizando câmeras termográficas portáteis, enquanto soluções mais modernas empregam drones equipados com sensores térmicos. Embora a utilização de drones agilize a captura de dados, o processo ainda exige que as imagens sejam analisadas individualmente pelo olhar humano de um técnico, que inspeciona visualmente os registros para diagnosticar as anomalias e direcionar as estratégias de manutenção.

O diagnóstico visual realizado por operadores humanos pode se tornar um processo demorado e suscetível a falhas ou inconsistências. Como sugestão de aprimoramento, este trabalho propõe a aplicação de técnicas de visão computacional para a análise de imagens termográficas de painéis solares. Por meio da integração de abordagens de visão clássica e algoritmos de aprendizado profundo, o objetivo é facilitar e acelerar a detecção de anomalias, fornecendo uma ferramenta mais robusta e eficiente para o diagnóstico de falhas nesses sistemas.

2 Dataset

Para o desenvolvimento e treinamento dos modelos de visão computacional, este trabalho utiliza o conjunto de dados público denominado *InfraredSolarModules*. Este *dataset* foi escolhido por fornecer imagens reais em infravermelho de diversas anomalias encontradas em usinas de geração solar. A literatura carece de bases de dados termográficas em larga escala disponíveis publicamente; portanto, a utilização desse *dataset* supre essa lacuna, viabilizando pesquisas em aprendizado de máquina voltadas para a otimização e eficiência da indústria fotovoltaica.

O *dataset* é composto por 20.000 imagens termográficas, cada uma possuindo uma resolução espacial de 24 por 40 pixels. Os dados estão estruturados e categorizados em 12 classes distintas que descrevem o estado de operação dos painéis. Dentre elas, 11 classes representam diferentes tipos de falhas ou degradações detectáveis por assinaturas térmicas, enquanto a classe restante, denominada "Sem Anomalia" (*No-Anomaly*), representa o caso nulo de um módulo operando em condições nominais. Os rótulos de cada amostra são organizados em um arquivo estruturado (JSON), que relaciona o diretório da imagem à sua respectiva classe de anomalia.

A Tabela 1 detalha as classes presentes na base de dados, a quantidade de imagens disponíveis para cada categoria e a descrição do comportamento termográfico associado.

Tabela 1: Distribuição e descrição das classes de anomalias no dataset *InfraredSolarModules*.

Classe	Imagens	Descrição
Cell	1.877	Ponto quente com geometria quadrada ocorrendo em uma única célula.
Cell-Multi	1.288	Pontos quentes com geometria quadrada ocorrendo em múltiplas células.
Cracking	941	Anomalia no módulo causada por rachaduras em sua superfície.
Hot-Spot	251	Ponto quente isolado em um módulo de filme fino (<i>thin film</i>).
Hot-Spot-Multi	247	Múltiplos pontos quentes em um módulo de filme fino.
Shadowing	1.056	Obstrução da luz solar causada por vegetação, outras estruturas ou fileiras de painéis.
Diode	1.499	Diodo de desvio (bypass) ativado, afetando tipicamente 1/3 do módulo.
Diode-Multi	175	Múltiplos diodos de desvio ativados, afetando tipicamente 2/3 do módulo.
Vegetation	1.639	Painéis obstruídos pelo crescimento de vegetação.
Soiling	205	Presença de terra, poeira ou outros detritos acumulados na superfície do módulo.
Offline-Module	828	Módulo inativo, caracterizado pelo aquecimento de toda a sua extensão.
No-Anomaly	10.000	Módulo solar operando em condições nominais, sem defeitos.

3 Solução com visão clássica

3.1 Preparação do ambiente e análise exploratória dos dados

O desenvolvimento do projeto foi centralizado na plataforma *Google Colab*, utilizando uma abordagem modular dividida em seções sequenciais. O conjunto de dados *InfraredSolarModules* foi importado diretamente do repositório remoto para o ambiente virtual de execução, sendo o arquivo *module_metadata.json* convertido em uma estrutura de tabela (*DataFrame* do *Pandas*) para correlacionar cada arquivo de imagem de 24x40 pixels à sua respectiva classe de anomalia.

Foi desenvolvida uma rotina para visualização e inspeção visual das matrizes brutas em tons de cinza. Durante esse processo de análise exploratória, identificou-se um comportamento indesejado de renderização da biblioteca *Matplotlib* (*pyplot.imshow*). Por padrão, a biblioteca aplica uma normalização automática de contraste baseada exclusivamente nos valores mínimos e máximos locais de cada imagem.

Essa característica fazia com que a visualização fosse prejudicada, painéis categorizados como nominais (*No-Anomaly*) apresentavam manchas e gradientes de calor inexistentes no mundo real, uma vez que variações irrelevantes eram esticadas para preencher toda a escala visual. A resolução desse problema e a calibração correta dos dados exigiram o travamento explícito dos limites de exibição nos valores absolutos do sensor infravermelho, utilizando os parâmetros matemáticos $vmin = 0$ e $vmax = 255$. A Figura 1 ilustra o impacto dessa correção, revelando a assinatura térmica uniforme real de um módulo saudável.




Figura 1: Impacto da normalização automática versus escala térmica absoluta (0-255) em módulo nominal.

3.2 Pipeline de análise inicial

A partir da estabilização visual dos dados, estabeleceu-se que os defeitos baseados em superaquecimento geométrico estrito (notadamente a classe *Cell*) possuíam forte assinatura no domínio do valor. Foi desenhado e implementado um *pipeline* clássico composto por quatro etapas sequenciais utilizando a biblioteca *OpenCV*:

1. **Limiarização binária** (*cv2.threshold*): operando diretamente na intensidade dos pixels, aplicou-se um limiar de corte ($T = 180$). Pixels com intensidade superior a T (zonas de alta temperatura) foram binarizados para branco (255), enquanto o restante da estrutura do painel foi mapeado para preto (0).

2. **Condicionamento espacial por morfologia matemática** (*cv2.morphologyEx*): na sequência utilizou-se uma operação morfológica composta de abertura (uma filtragem de erosão seguida por dilatação). Dado o tamanho reduzido das imagens (24x40 pixels), calibrou-se um elemento estruturante (*kernel*) compacto de dimensões 2×2 preenchido por uns. A erosão eliminou os pixels isolados de ruído, enquanto a subsequente dilatação restaurou a massa geométrica da anomalia principal.
3. **Extração de características e medição de contornos** (*cv2.findContours*): a imagem binária condicionada foi submetida a um algoritmo de varredura geométrica para identificar contornos externos. A partir das fronteiras localizadas, calculou-se a área em pixels da maior mancha quente de cada imagem por meio da função *cv2.contourArea*.
4. **Classificação heurística baseada em regras:** como fechamento da lógica, estruturou-se um decisor heurístico simples fundamentado na dimensão da área segmentada:
 - Se a maior área fosse inferior a 5 pixels, o módulo era classificado como *No-Anomaly*;
 - Se a área superasse 700 pixels (indicando que praticamente toda a matriz 24x40 atingiu saturação térmica), o módulo era mapeado como *Offline-Module*;
 - Áreas intermediárias sobreviventes eram rotuladas como anomalias puntiformes da classe *Cell*.

3.3 Extração de características e comparação de classificadores

O *pipeline* heurístico da seção anterior, embora eficaz para defeitos com forte assinatura geométrica como a classe *Cell*, mostra-se limitado: por basear-se em uma única medida (a área da maior mancha quente) e em limiares fixos, ele cobre apenas um pequeno subconjunto das doze classes do problema. Para superar essa limitação, adotou-se uma abordagem baseada em aprendizado de máquina, na qual cada imagem é convertida em um vetor de características numéricas e a classificação passa a ser aprendida a partir dos dados, em vez de definida por regras manuais.

Foi elaborado um conjunto inicial de 25 características que sumarizam o conteúdo de cada imagem termográfica sob diferentes aspectos: estatísticas de intensidade (média, desvio padrão, máximo, mínimo e percentil 90); descritores da região quente segmentada por limiarização de Otsu (fração de pixels quentes, número de manchas, área, extensão e razão de aspecto da maior mancha, além da cobertura por linha e por coluna); fração de região fria; densidade de bordas (*Canny*); textura média (gradiente de *Sobel*); medidas de simetria horizontal e vertical; e um histograma de intensidades com oito faixas.

Sobre esse conjunto de características, avaliaram-se quatro classificadores de naturezas distintas: *Random Forest* (conjunto de árvores por agregação), *Gradient Boosting* (árvores em sequência que corrigem o erro das anteriores), *Support Vector Machine* (SVM, com normalização das características) e *XGBoost* (*gradient boosting* otimizado). Todos os modelos foram treinados com tratamento do desbalanceamento das classes e avaliados sobre a mesma partição de teste (30% dos dados, estratificada). A Tabela 2 apresenta a acurácia e o *F1-score* macro de cada modelo. Adota-se o *F1-score* macro como métrica principal por atribuir peso igual a todas as classes, evidenciando o desempenho nas categorias minoritárias, que de outro modo seriam ofuscadas pela classe majoritária *No-Anomaly*.

A Tabela 3 detalha o *F1-score* por classe de cada modelo, permitindo localizar com maior precisão onde cada classificador acerta ou falha.

Os resultados evidenciam a superioridade dos métodos baseados em árvores, com destaque para o *XGBoost*, que obteve o melhor desempenho tanto em acurácia quanto em *F1-score* macro. O salto em relação à heurística inicial confirma a vantagem de combinar múltiplas características com um classificador

Tabela 2: Comparação dos classificadores sobre o conjunto base de 25 características.

Modelo	Acurácia	F1-score macro
XGBoost	66,6%	42,2%
Random Forest	61,9%	41,9%
Gradient Boosting	54,3%	38,5%
SVM	42,0%	32,9%

Tabela 3: *F1-score* (%) por classe de cada modelo sobre o conjunto base de características.

Classe	Random Forest	Gradient Boosting	SVM	XGBoost
Cell	45,7	42,7	39,5	48,5
Cell-Multi	29,3	31,6	22,4	31,8
Cracking	65,1	62,5	63,3	66,0
Diode	61,0	58,3	57,6	67,4
Diode-Multi	27,5	23,3	11,1	20,0
Hot-Spot	17,7	11,3	7,8	10,3
Hot-Spot-Multi	32,2	27,6	13,8	39,4
No-Anomaly	79,3	71,4	55,6	83,2
Offline-Module	35,8	32,4	28,5	37,9
Shadowing	43,6	37,5	36,8	42,9
Soiling	20,0	21,1	18,7	13,6
Vegetation	45,7	42,8	39,9	44,9

treinado. Ainda assim, os valores relativamente modestos do *F1-score* macro indicam dificuldade na distinção entre classes minoritárias e visualmente semelhantes, o que motiva o refinamento do conjunto de características descrito na seção seguinte.

4 Solução com *deep learning*

Para a tarefa de identificação e classificação de anomalias em imagens termográficas, este trabalho emprega redes neurais convolucionais, dada a sua eficácia na extração de características em problemas de visão computacional. Optou-se pela utilização da arquitetura ResNet34, ajustada aos dados específicos da pesquisa por meio de técnicas de aprendizado por transferência.

A primeira etapa do desenvolvimento consistiu no pré-processamento e balanceamento da base de dados. Visando evitar o enviesamento do modelo em direção à classe majoritária, a categoria correspondente aos painéis operando em condições normais (*No-Anomaly*) foi subamostrada aleatoriamente, sendo reduzida do seu total original de 10.000 amostras para 1.800 imagens. Além disso, para agrupar comportamentos térmicos equivalentes e mitigar redundâncias, algumas classes anômalas foram consolidadas. Ocorrências múltiplas de um mesmo defeito, registradas nos rótulos *Cell-Multi*, *Diode-Multi* e *Hot-Spot-Multi*, foram incorporadas respectivamente às suas categorias raízes: *Cell*, *Diode* e *Hot-Spot*. A distribuição estrutural do conjunto de dados após o processamento encontra-se detalhada na Tabela 4.

Tabela 4: Distribuição atualizada das classes.

Classe	Número de Imagens
Cell	3.165
No-Anomaly	1.800
Diode	1.674
Vegetation	1.639
Shadowing	1.056
Cracking	940
Offline-Module	827
Hot-Spot	495
Soiling	204

Com os dados organizados, o treinamento do modelo foi estruturado visando o melhor refinamento dos pesos da rede. Para realizar essa etapa, aplicou-se um método exploratório de busca pela melhor taxa de aprendizado, que permite identificar empiricamente a faixa de valores ideal onde a otimização atua de maneira mais eficiente e estável. A Figura 2 ilustra o comportamento da função de perda em resposta à variação da taxa de aprendizado durante este teste.




Figura 2: Função de perda em resposta à variação da taxa de aprendizado.

A rede foi então treinada aplicando o ajuste fino com base na faixa ideal descoberta. Como resultado, o modelo ResNet34 alcançou uma precisão de 67% e um $F1-score$ de 65% no diagnóstico das classes. Os números não indicam onde o modelo acerta ou erra, portanto, para aprofundar a análise a respeito do desempenho de identificação por categoria, extraiu-se a matriz de confusão das predições em relação ao conjunto de teste, na qual é possível constatar a distribuição dos acertos, que estão concentrados na diagonal principal, e dos falsos positivos, conforme exposto na Figura 3.

Confusion matrix

Actual	Cell	443	37	5	1	59	14	19	1	60
	Cracking	29	115	1	9	6	1	5	0	3
	Diode	5	0	308	2	5	5	0	0	3
	Hot-Spot	4	1	2	71	14	3	10	0	3
	No-Anomaly	47	0	5	3	243	21	18	1	32
	Offline-Module	26	2	2	1	27	77	6	0	10
	Shadowing	26	4	1	9	22	7	151	0	11
	Soiling	15	11	1	8	5	0	0	4	2
	Vegetation	82	6	3	4	39	9	10	0	165
		Predicted								
		Cell	Cracking	Diode	Hot-Spot	No-Anomaly	Offline-Module	Shadowing	Soiling	Vegetation

Figura 3: Matriz de confusão resultante das predições do modelo ResNet34.

Analisando a matriz, observa-se que o modelo apresenta um desempenho consistente nas categorias com maior volume de amostras. Contudo, o principal ponto de vulnerabilidade do classificador manifesta-se na classe *Soiling*, que exibe uma taxa de erro mais acentuada em comparação às demais. Esse comportamento está diretamente associado à escassez de dados dessa categoria, que possui apenas 204 registros na base consolidada, limitando a capacidade da rede neural de extrair e generalizar características visuais para essa anomalia.

Para ilustrar o funcionamento do modelo, a Figura 4 demonstra uma amostra das classificações, comparando a resposta predita pela rede neural com o rótulo original da imagem.




Figura 4: Amostra da operação do modelo.

Embora os resultados iniciais validem a viabilidade da técnica, limitações foram identificadas durante os experimentos. Tentativas preliminares de compensar o desbalanceamento do número de amostras por meio da aplicação de pesos resultaram em uma degradação no desempenho geral do modelo, reduzindo tanto a precisão quanto o *F1-score*. Diante disso, como proposta de melhoria, sugere-se a exploração de técnicas de *data augmentation*. Contudo, destaca-se que modificações artificiais de brilho e contraste devem ser evitadas, visto que em imagens termográficas, a intensidade dos pixels está relacionada à temperatura do módulo, de modo que alterações dessa natureza descaracterizariam os padrões reais das anomalias e da operação nominal dos painéis solares.

5 Conclusão